

Санкт-Петербургский политехнический университет Петра Великого
Институт прикладной математики и механики
Высшая школа прикладной математики и вычислительной физики

ОТЧЁТ ПО ЛАБОРАТОРНОЙ РАБОТЕ №4

по дисциплине
«Математическая статистика»

Выполнил студент
группы 3630102/80401

Веденичев Дмитрий Александрович

Проверил
Доцент, к.ф.-м.н.

Баженов Александр Николаевич

Санкт-Петербург
2021

СОДЕРЖАНИЕ

СПИСОК ИЛЛЮСТРАЦИЙ	3
1 Постановка задачи	4
2 Теория	4
2.1 Эмпирическая функция распределения	4
2.1.1 Статистический ряд	4
2.1.2 Эмпирическая функция распределения	4
2.1.3 Нахождение э. ф. р.	4
2.2 Оценки плотности вероятности	5
2.2.1 Определение	5
2.2.2 Ядерные оценки	5
3 Программная реализация	5
4 Результаты	6
4.1 Эмпирическая функция распределения	6
4.2 Ядерные оценки плотности распределения	8
5 Обсуждение	15
6 Приложение	16

СПИСОК ИЛЛЮСТРАЦИЙ

1	Нормальное распределение	6
2	распределение Лапласа	6
3	распределение Коши	7
4	Равномерное распределение	7
5	распределение Пуассона	8
6	распределение Коши, $n=20$	8
7	распределение Коши, $n=60$	9
8	распределение Коши, $n=100$	9
9	Нормальное распределение, $n=20$	10
10	Нормальное распределение, $n=60$	10
11	Нормальное распределение, $n=100$	11
12	распределение Лапласа, $n=20$	11
13	распределение Лапласа, $n=60$	12
14	распределение Лапласа, $n=100$	12
15	распределение Пуассона, $n=20$	13
16	распределение Пуассона, $n=60$	13
17	распределение Пуассона, $n=100$	14
18	Равномерное распределение, $n=20$	14
19	Равномерное распределение, $n=60$	15
20	Равномерное распределение, $n=100$	15

1 Постановка задачи

Сгенерировать выборки размером 20, 60 и 100 элементов. Построить на них эмпирические функции распределения и ядерные оценки плотности распределения на отрезке $[-4; 4]$ для непрерывных распределений и на отрезке $[6; 14]$ для распределения Пуассона.

2 Теория

2.1 Эмпирическая функция распределения

2.1.1 Статистический ряд

Статистическим рядом назовем совокупность, состоящую из последовательности $\{z_i\}_{i=1}^k$ попарно различных элементов выборки, расположенных по возрастанию, и последовательности $\{n_i\}_{i=1}^k$ частот, с которыми эти элементы содержатся в выборке.

2.1.2 Эмпирическая функция распределения

Эмпирическая функция распределения (э. ф. р.) - относительная частота события $X < x$, полученная по данной выборке:

$$F_n^*(x) = P^*(X < x). \quad (1)$$

2.1.3 Нахождение э. ф. р.

$$F_n^*(x) = \frac{1}{n} \sum_{z_i < x} n_i. \quad (2)$$

$F^*(x)$ — функция распределения дискретной случайной величины X^* , заданной таблицей распределения

X^*	z_1	z_2	\dots	z_k
P	n_1/n	n_2/n	\dots	n_k/n

Таблица 1: Таблица распределения

Эмпирическая функция распределения является оценкой, т. е. приближённым значением, генеральной функции распределения

$$F_n^*(x) \approx F_X(x). \quad (3)$$

2.2 Оценки плотности вероятности

2.2.1 Определение

Оценкой плотности вероятности $f(x)$ называется функция $\hat{f}(x)$, построенная на основе выборки, приближённо равная $f(x)$

$$\hat{f}(x) \approx f(x). \quad (4)$$

2.2.2 Ядерные оценки

Представим оценку в виде суммы с числом слагаемых, равным объёму выборки:

$$\hat{f}_n(x) = \frac{1}{nh_n} \sum_{i=1}^n K\left(\frac{x - x_i}{h_n}\right). \quad (5)$$

$K(u)$ - ядро, т. е. непрерывная функция, являющаяся плотностью вероятности, x_1, \dots, x_n - элементы выборки, а $\{h_n\}_{n \in \mathbb{N}}$ - последовательность элементов из \mathbb{R}_+ такая, что

$$h_n \xrightarrow{n \rightarrow \infty} 0; \quad nh_n \xrightarrow{n \rightarrow \infty} \infty. \quad (6)$$

Такие оценки называются непрерывными ядерными.

Гауссово ядро:

$$K(u) = \frac{1}{\sqrt{2\pi}} e^{-\frac{u^2}{2}}. \quad (7)$$

Правило Сильвермана:

$$h_n = \left(\frac{4\hat{\sigma}^5}{3n}\right)^{1/5} \approx 1.06\hat{\sigma}n^{-1/5}, \quad (8)$$

где $\hat{\sigma}$ - выборочное стандартное отклонение.

3 Программная реализация

Лабораторная работа выполнена на языке Python версии 3.9 в среде разработки PyCharm. Использовались дополнительные библиотеки:

1. scipy
2. statsmodels
3. matplotlib
4. seaborn

5. numpy

6. math

В приложении находится ссылка на GitHub репозиторий с исходным кодом.

4 Результаты

4.1 Эмпирическая функция распределения

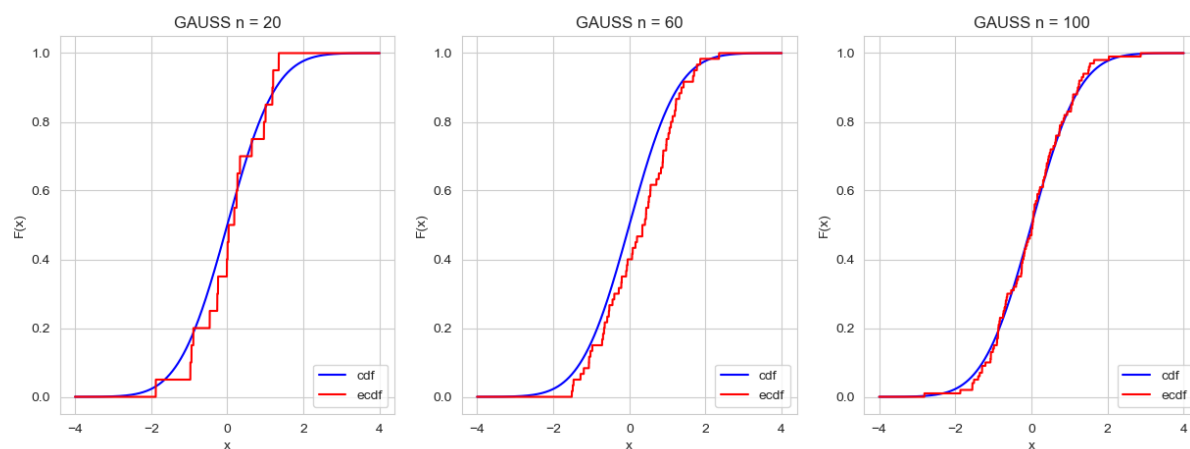


Рис. 1: Нормальное распределение

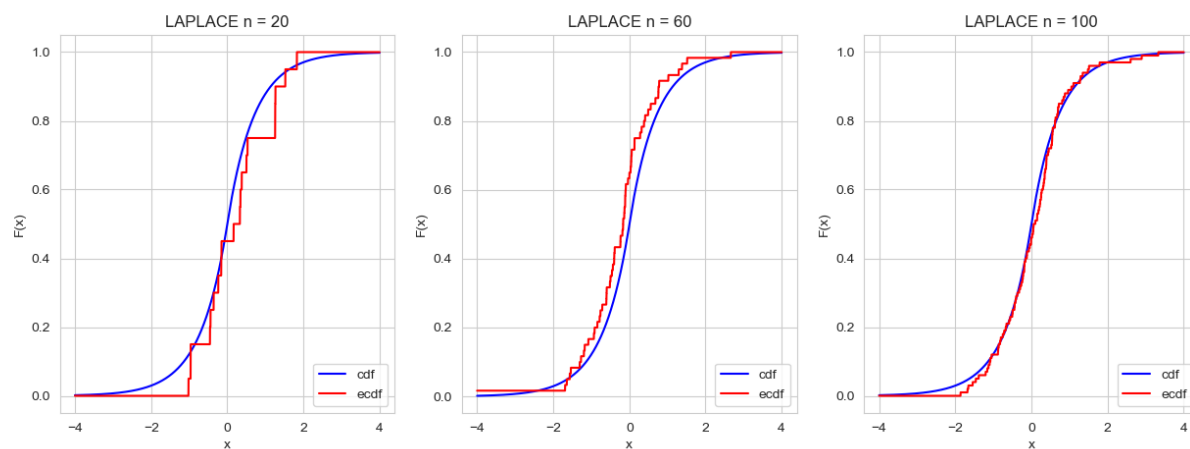


Рис. 2: распределение Лапласа




Рис. 3: распределение Коши

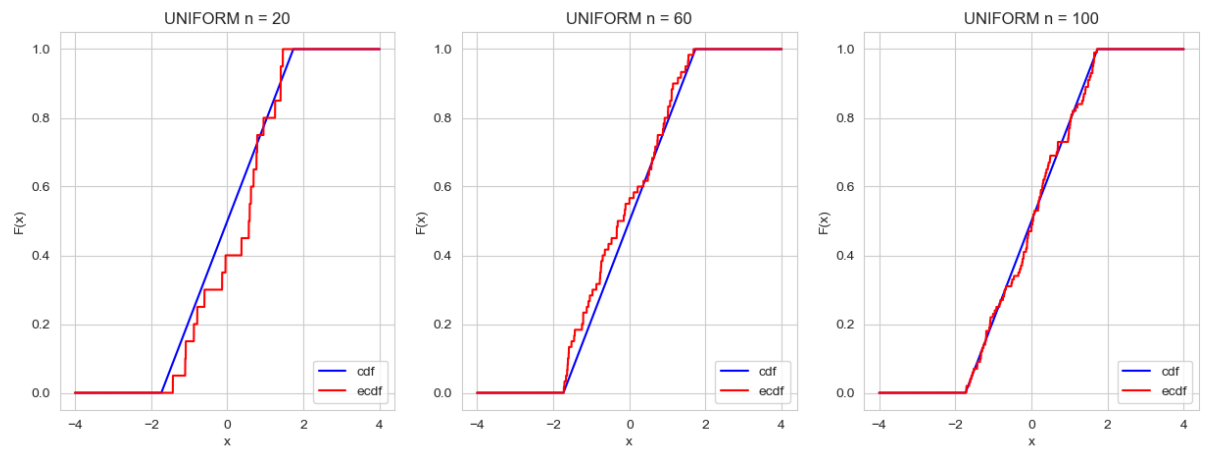


Рис. 4: Равномерное распределение

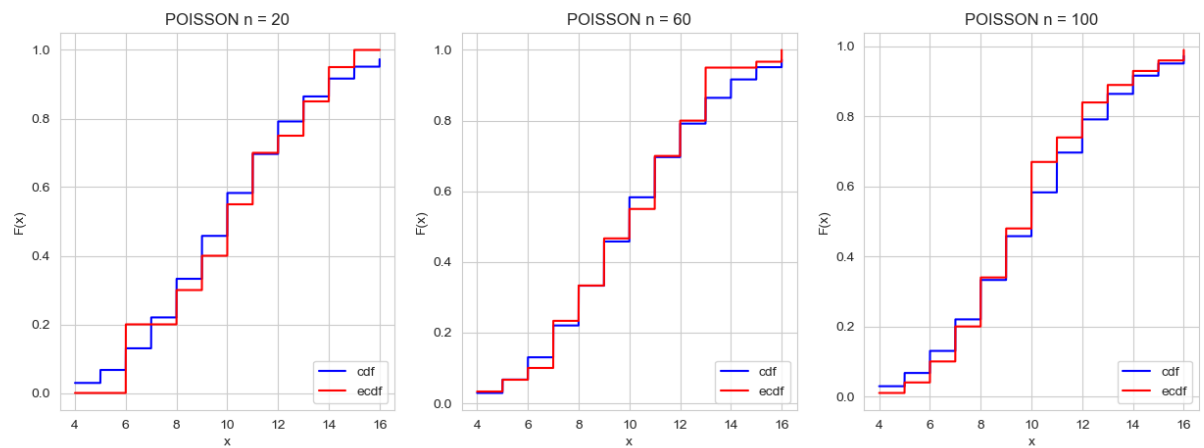


Рис. 5: распределение Пуассона

4.2 Ядерные оценки плотности распределения

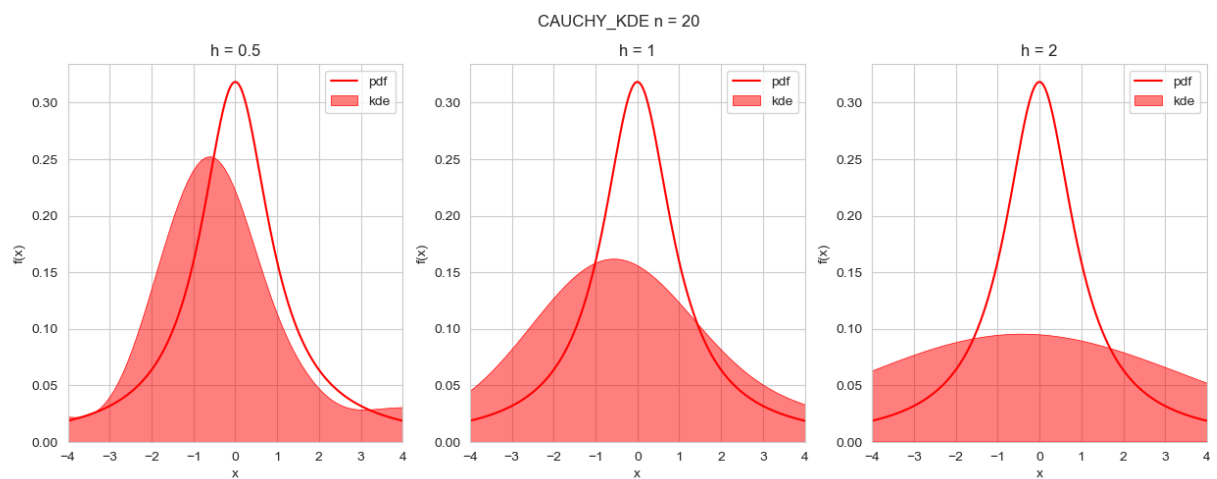


Рис. 6: распределение Коши, $n=20$




Рис. 7: распределение Коши, $n=60$

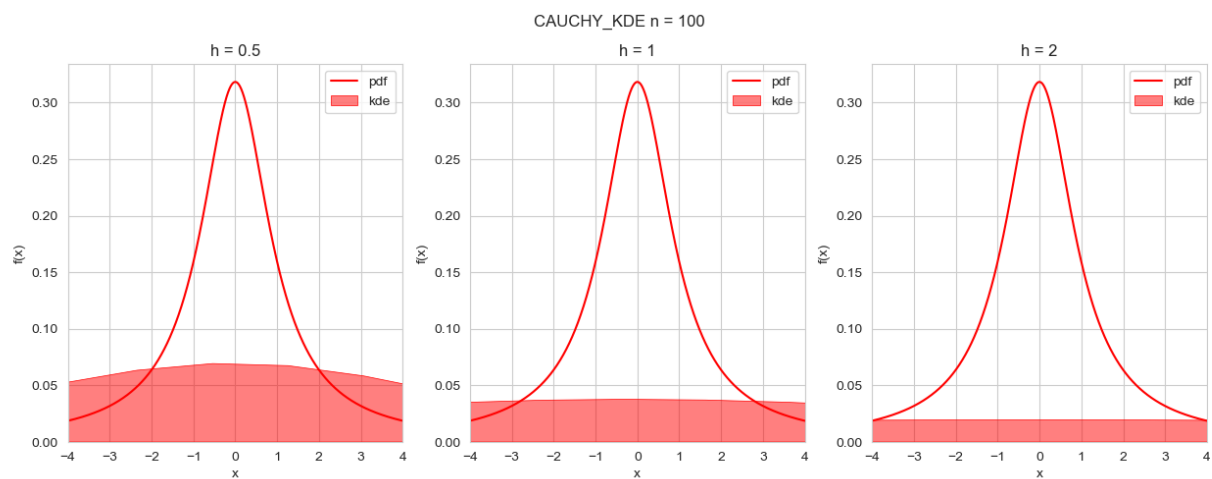




Рис. 8: распределение Коши, $n=100$

Рис. 9: Нормальное распределение, $n=20$ Рис. 10: Нормальное распределение, $n=60$

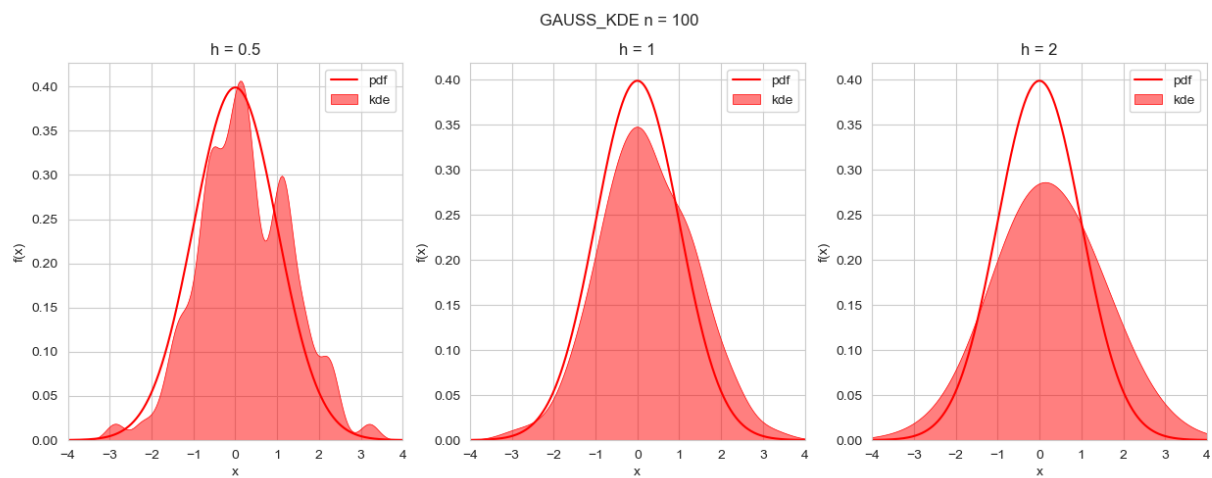


Рис. 11: Нормальное распределение, $n=100$


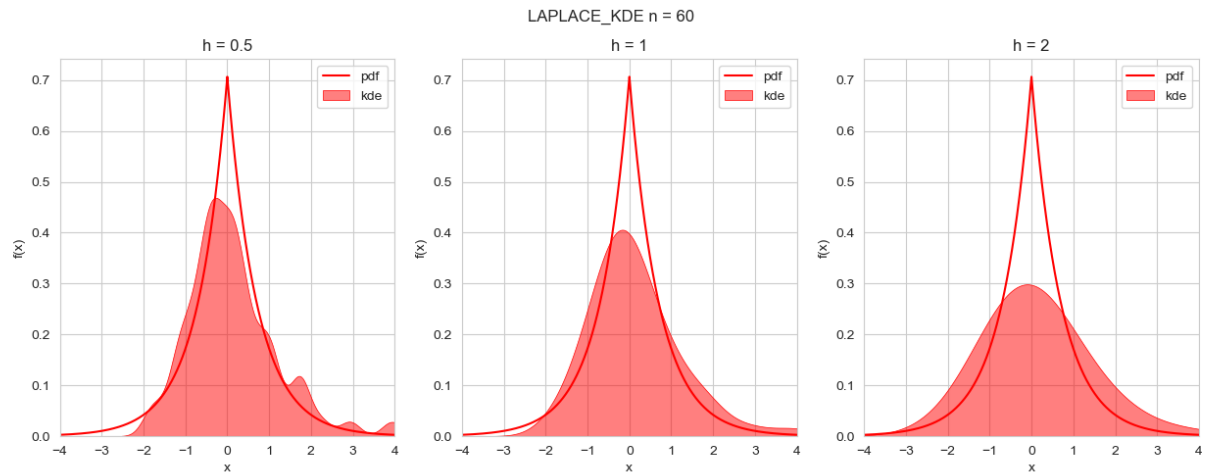

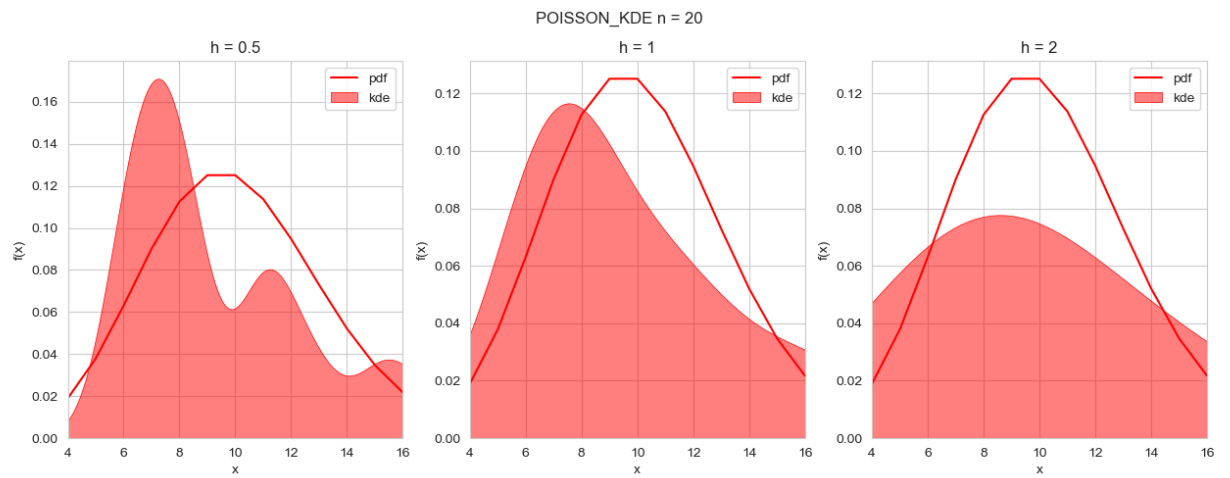
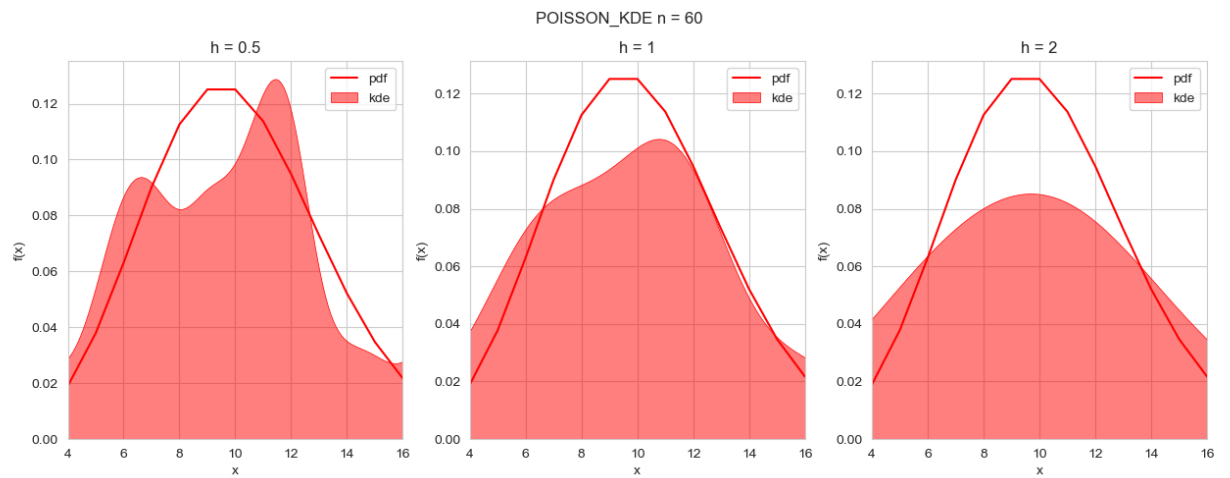


Рис. 12: распределение Лапласа, $n=20$

Рис. 13: распределение Лапласа, $n=60$ Рис. 14: распределение Лапласа, $n=100$

Рис. 15: распределение Пуассона, $n=20$ Рис. 16: распределение Пуассона, $n=60$

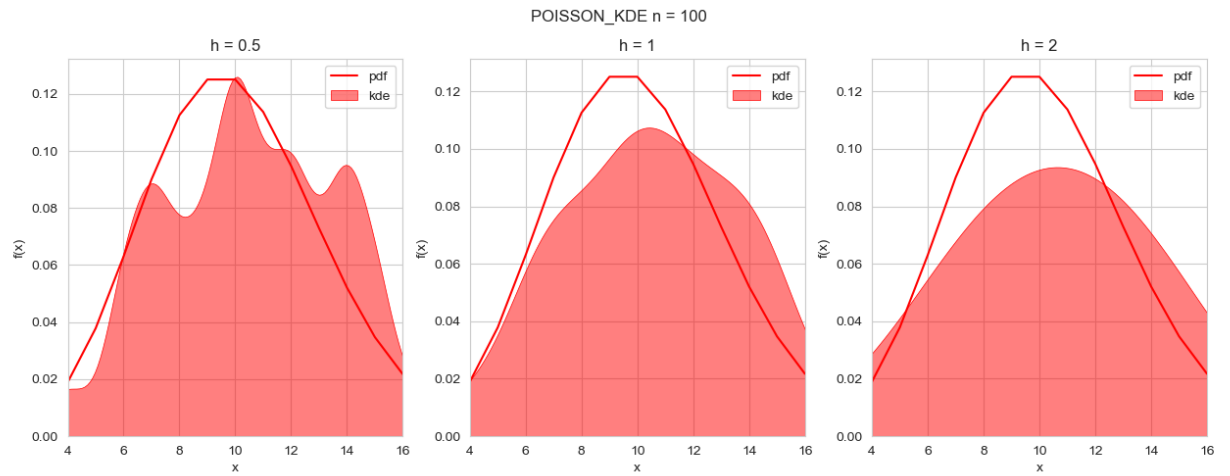


Рис. 17: распределение Пуассона, $n=100$


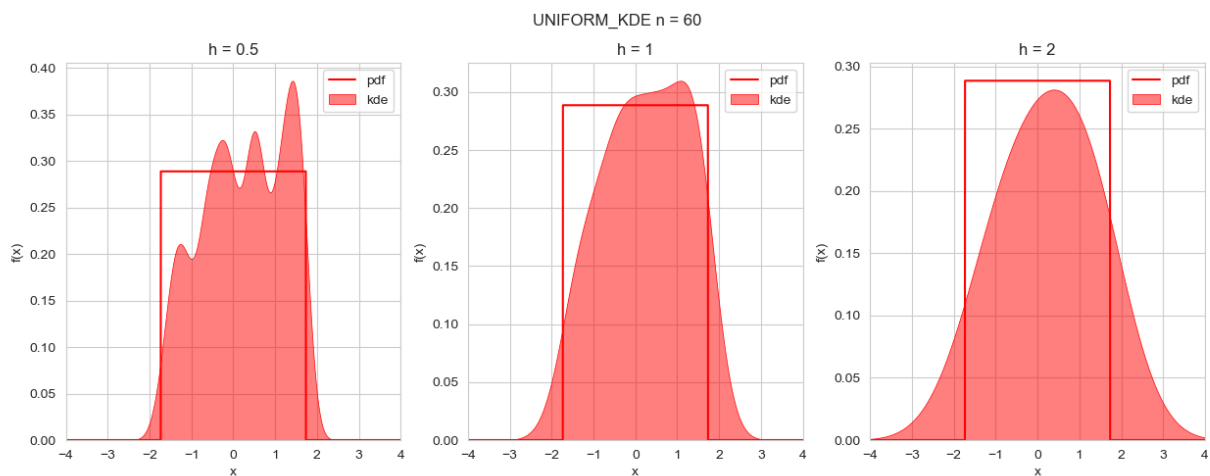
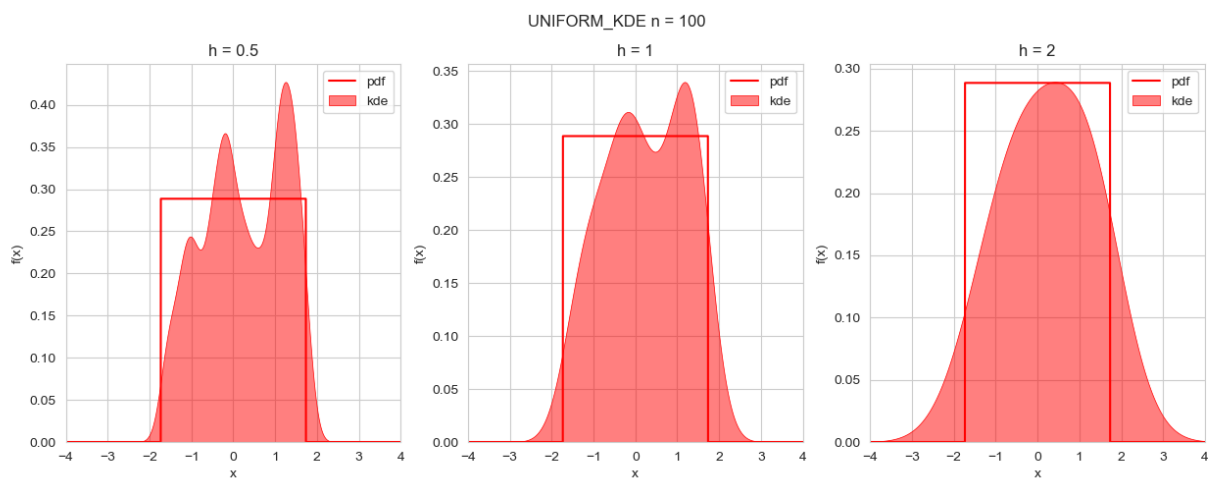


Рис. 18: Равномерное распределение, $n=20$

Рис. 19: Равномерное распределение, $n=60$ Рис. 20: Равномерное распределение, $n=100$

5 Обсуждение

Можем наблюдать на иллюстрациях с эмпирическими функциями, что ступенчатая эмпирическая функция распределения тем лучше приближает функцию распределения реальной выборки, чем мощнее эта выборка. Заметим так же, что для распределения Пуассона и равномерного распределения отклонение функций друг от друга наибольшее.

Рисунки, посвященные ядерным оценкам, иллюстрируют сближение ядерной оценки и функции плотности вероятности для всех h с ростом размера выборки. Для распределения Пуассона

наиболее ярко видно, как сглаживает отклонения увеличение параметра сглаживания h .

В зависимости от особенностей распределений для их описания лучше подходят разные параметры h в ядерной оценке: для нормального, равномерного и распределения Пуассона оптимальным значением параметра является $h = h_n$, а для распределений Коши и Лапласа - $h = h_n/2$.

Также можно увидеть, что чем больше коэффициент при параметре сглаживания \hat{h}_n , тем меньше изменений знака производной у аппроксимирующей функции, вплоть до того, что при $h = 2h_n$ функция становится унимодальной на рассматриваемом промежутке. Также видно, что при $h = h_n/2$ по полученным приближениям становится сложно сказать плотность вероятности какого распределения они должны повторять, так как они очень похожи между собой.

6 Приложение

Код программы GitHub URL:

https://github.com/PopeyeTheSailorsCat/math_stat_2021/blob/main/lab4/src/lab4.py